MAESTRIA EN INTELIGENCIA ARTIFICIAL

MATERIA

PROYECTO INTEGRADOR DE INTELIGENCIA ARTIFICIAL

DOCENTE ACADEMICO

ALEXANDRA JACQUELINE ARCINIEGAS CORAL

ALUMNOS:

ROMMEL GREGORY PACHECO FLORES

KEVIN BILL UBE ALVARO

TEMA:

ANALISIS EXPLORATORIO DE DATO (EDA)

04-04-2026

PERIODO LECTIVO

2025-2026

1. Introducción

El análisis exploratorio de datos constituye la etapa que permite comprender la estructura empírica de un conjunto de datos antes del modelado. En proyectos de machine learning, esta fase no se limita a producir visualizaciones, sino que busca detectar sesgos, problemas de calidad, distribuciones extremas, redundancias y patrones potencialmente útiles para la predicción (Tukey, 1977); (Gareth James, 2021).

En el contexto de cobranzas, el EDA es especialmente relevante porque las variables suelen combinar información transaccional, histórica y operativa. Una mala interpretación de los nulos, una variable codificada de forma indebida o una fuga temporal puede debilitar de forma importante la validez del modelo. Por ello, este informe revisa el dataset desde cuatro perspectivas simultáneas: analítica, tecnológica, operativa y académica.

2. Comprensión del dataset y contexto analítico

El dataset analizado, `features_ml.csv`, resume información proveniente de cuatro tablas transaccionales del sistema: clientes, facturas, gestiones de cobranza y promesas de pago. La unidad de entrenamiento no es la factura en sentido estricto, sino el corte de scoring por factura; en consecuencia, una misma factura puede aportar múltiples filas al dataset si tuvo varias gestiones.

Tabla	Filas	Columnas
Clientes	200	6
Facturas	5338	9
Gestiones_Cobranza	14333	9
Promesas_Pago	1741	7
Features_Ml	19671	36

Tabla 1. Estructura general de las tablas fuente y del dataset de features.

El archivo de features contiene 19,671 filas y 36 columnas, que representan 5,338 facturas únicas de 200 clientes. El rango temporal de `fecha_corte` va del 2023-01-01 al 2025-07-16. Esta estructura es consistente con el diseño del proyecto, en el que el riesgo se actualiza dinámicamente a medida que avanza la cobranza.

Metodológicamente, esto implica que el EDA debe interpretar cualquier patrón tanto por fila como por factura. Una observación clave es que las facturas más problemáticas generan más cortes y, por ende, más peso relativo en el dataset por filas. Esa característica no es un error, pero sí modifica la lectura del desbalance.

3. Revisión de la calidad de los datos

Chequeo	Valor
Filas totales	19671
Columnas totales	36
Facturas únicas	5338
Clientes únicos	200
Duplicados exactos	0
Duplicados por factura_id + num_corte	0
Montos <= 0	0
Antigüedad <= 0	0
Condición de días inválida	0
Sectores one-hot inválidos	0
Tasa_cumplimiento fuera de [0,1]	0
Tasa_contacto_cliente fuera de [0,1]	0
Tasa_cumpl_promesas fuera de [0,1]	0

Tabla 2. Resultados de la revisión estructural y de consistencia.

En términos de calidad, el dataset presenta un comportamiento favorable. No se detectaron duplicados exactos ni duplicados por combinación `factura_id + num_corte`. Tampoco se identificaron montos no positivos, antigüedad inválida, condiciones de pago fuera del catálogo permitido ni tasas fuera del rango [0,1].

Variable	Nulos	% nulos
dias_desde_ultima_gestion	5338	27.14%
ultimo_resultado_enc	5338	27.14%

Tabla 3. Variables con valores faltantes.

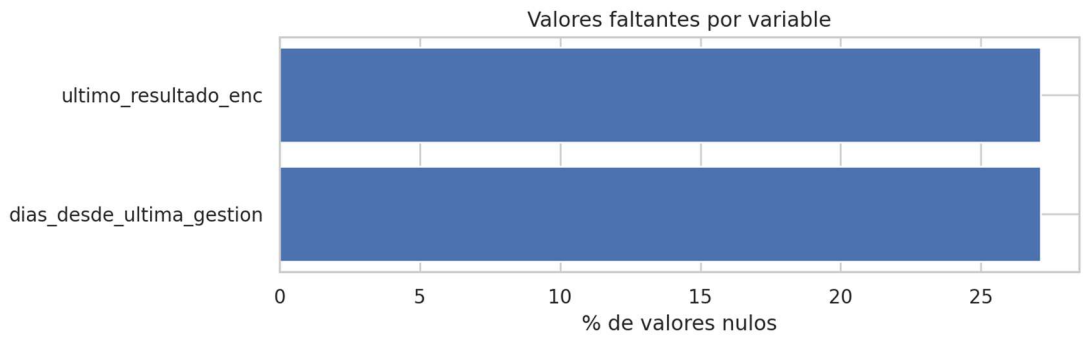

Figura 1. Porcentaje de valores faltantes por variable.

Solo se detectan nulos en `dias_desde_ultima_gestion` y `ultimo_resultado_enc`, ambas con 5,338 registros faltantes (27.14%). El patrón no es aleatorio: coincide exactamente con los cortes 0, donde todavía no existen gestiones asociadas a la factura. Por tanto, estos faltantes deben interpretarse como ausencia estructural coherente con la lógica temporal del sistema.

Una advertencia importante de modelado es la codificación de `ultimo_resultado_enc` como variable numérica de 0 a 8. Aunque funcional para ciertos modelos basados en árboles, en modelos lineales o en clustering esta representación puede inducir un orden artificial que no necesariamente existe en el negocio. En ese caso, convendría evaluar una codificación one-hot u otro tratamiento categórico.

4. Estadísticas descriptivas principales

Variable	Media	Mediana	Desv. est.	P95	P99	Máx.	Asimetría
Monto	28173.43	14013.53	32780.68	106803.43	142429.41	149413.99	1.81
Mora_Promedio_Hist	23.92	18.89	20.9	58.59	67.75	119.0	0.56
Mora_Ultimo_Tramo	20.46	14.67	21.02	60.0	78.0	119.0	0.97
Tasa_Cumplimiento	0.43	0.36	0.39	1.0	1.0	1.0	0.31
Ratio_Monto	1.09	1.0	0.84	2.09	3.26	22.81	6.19
Num_Gestiones_Factura	2.31	2.0	2.33	7.0	9.0	10.0	1.07
Dias_Desde_Ultima_Gestion	22.59	14.0	23.67	75.0	99.68	155.0	1.57
tasa_contacto_cliente	0.54	0.52	0.17	0.83	1.0	1.0	0.25
num_promesas_rotas	2.72	1.0	3.64	10.0	16.0	21.0	1.77
tasa_cumpl_promesas	0.6	0.6	0.37	1.0	1.0	1.0	-0.26
promesas_total	5.0	3.0	5.4	16.0	22.0	32.0	1.29

Tabla 4. Estadísticas descriptivas de variables seleccionadas.

Las estadísticas descriptivas muestran que el dataset combina variables de naturaleza muy distinta: montos monetarios, tasas acotadas entre 0 y 1, conteos discretos y variables de tiempo.

Esta heterogeneidad de escala respalda la necesidad de preprocesamiento diferenciado según el algoritmo (Kuhn & Johnson, 2019)

El `monto` presenta una media de 28173.43 y una mediana de 14013.53, con asimetría positiva de 1.81; ello sugiere una distribución sesgada a la derecha, esperable en carteras comerciales donde unas pocas facturas concentran gran exposición. `ratio_monto` es todavía más extremo: mediana de 1.00, máximo de 22.81 y asimetría de 6.19, lo que indica episodios puntuales donde el monto de la factura se desvía fuertemente del patrón histórico del cliente.

`mora_promedio_hist` registra una media de 23.92 días y una mediana de 18.89, mientras que `num_gestiones_factura` muestra una media de 2.31 y mediana de 2. Desde negocio, ambas variables son plausibles como señales de riesgo: la primera resume conducta histórica de pago; la segunda refleja intensidad de seguimiento sobre la factura.

5. Análisis de distribuciones

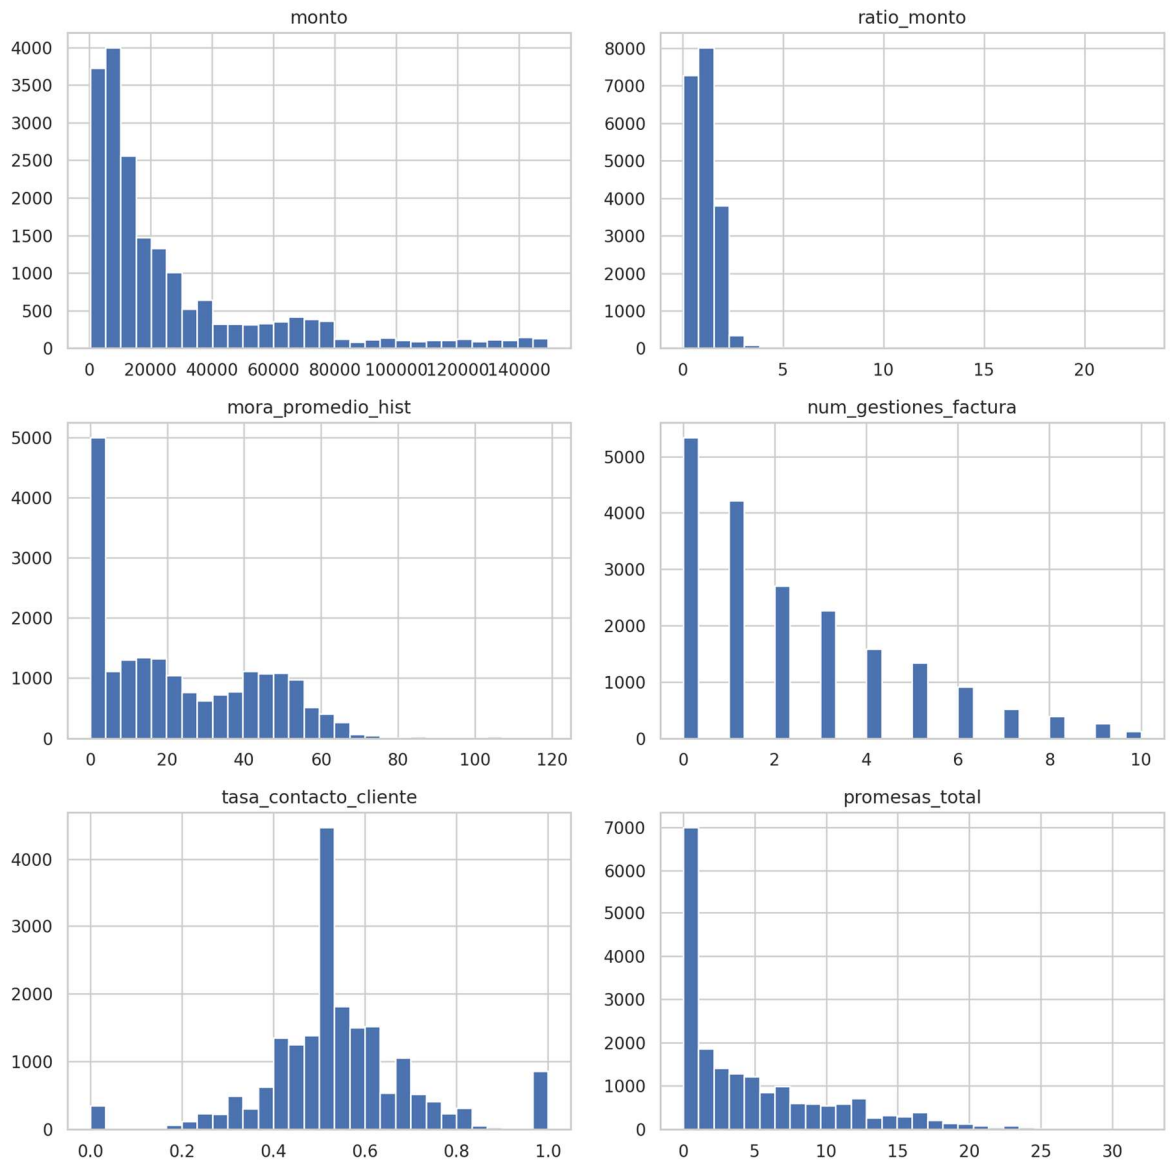

Figura 2. Distribuciones de variables numéricas clave.

Las distribuciones confirman que el dataset no responde a un patrón gaussiano simple. `monto`, `ratio_monto`, `promesas_total` y `num_promesas_rotas` exhiben colas derechas, mientras que variables como `tasa_contacto_cliente` y `tasa_cumpl_promesas` se mantienen acotadas en [0,1] con concentración en intervalos medios y altos.

En términos de cobranza, estas formas son coherentes con el dominio. Un número elevado de promesas o de promesas rotas no debería ser frecuente en toda la cartera, pero sí puede concentrarse en un subconjunto pequeño de clientes o facturas problemáticas. Del mismo modo,

un `ratio_monto` alto puede indicar una factura atípicamente grande para el comportamiento histórico del cliente, lo que podría incrementar el riesgo operativo o de recuperación.

6. Variable objetivo y variables categóricas

Target	Conteo filas	% filas	Conteo facturas	% facturas
on_time	3317	16.86%	2217	41.53%
+30	3713	18.88%	1246	23.34%
+30	5965	30.32%	1088	20.38%
+90	6676	33.94%	787	14.74%

Tabla 5. Distribución del target por filas y por facturas únicas.

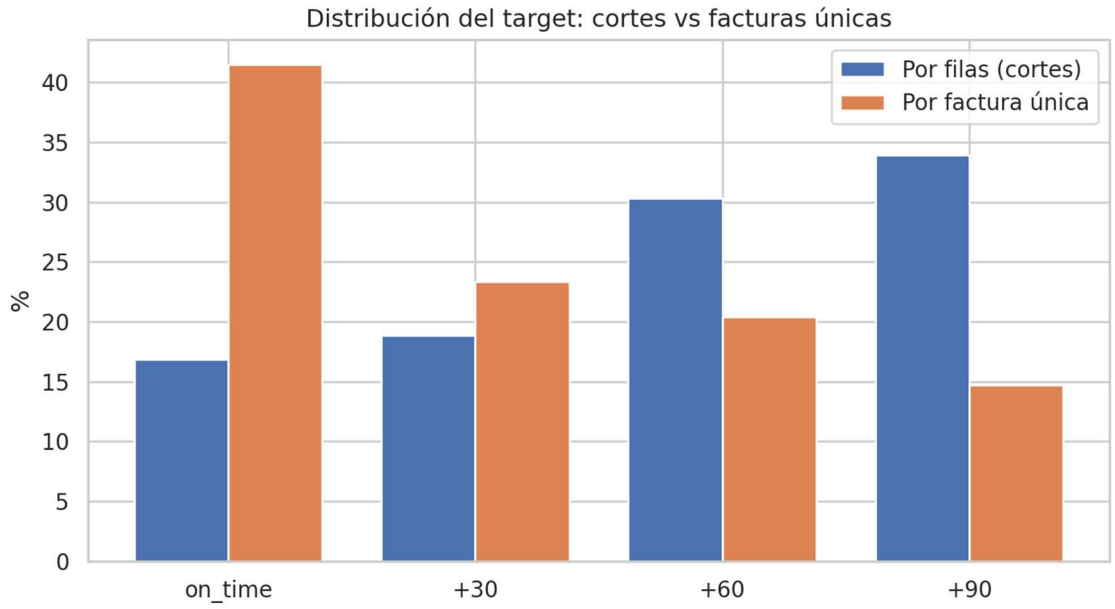

Figura 3. Comparación del target por cortes y por facturas únicas.

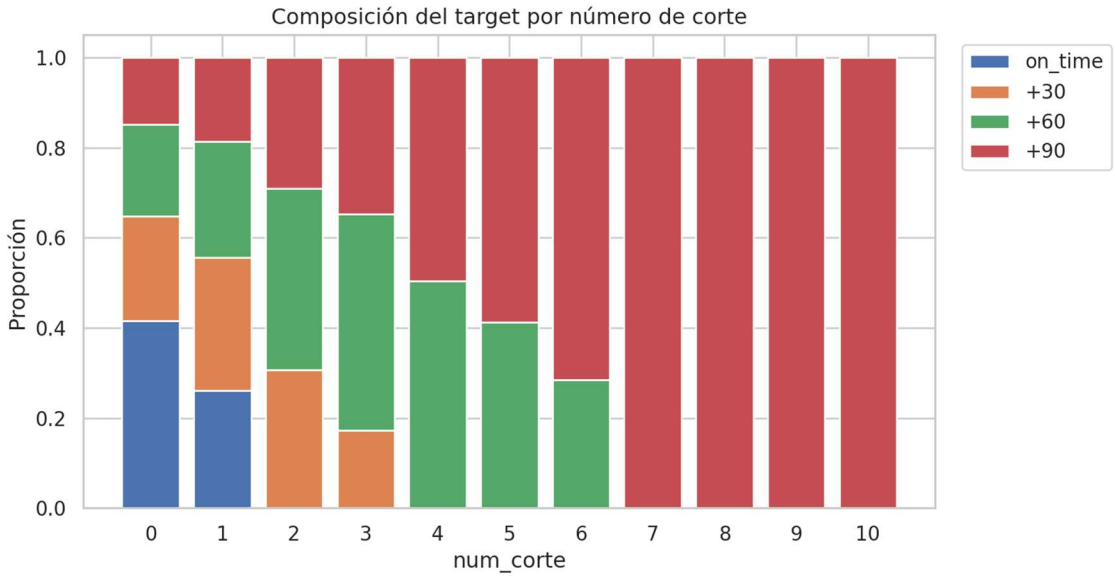

Figura 4. Distribución del target según el número de corte.

El comportamiento del target cambia de forma importante según la unidad de análisis. Por filas, las clases severas dominan el dataset: `+90` representa 33.94% y `+60` 30.32%. Sin embargo, por factura única, la clase `on_time` pasa a ser la más frecuente con 41.53%, mientras que `+90` cae a 14.74%.

Esta divergencia se explica por la propia lógica del scoring dinámico: las facturas con problemas generan más gestiones y, en consecuencia, más filas. La lectura correcta es que existe un desbalance moderado por factura y un desbalance más severo por corte. Por ello, métricas como F1-macro y recall por clase resultan más apropiadas que la accuracy simple (He & Garcia., 2009).

La figura por `num_corte` añade un hallazgo metodológico relevante: desde el corte 2 ya no aparecen casos `on_time`, y desde el corte 4 desaparece `+30`. Esto no implica fuga de información, pero sí evidencia un cambio de composición por etapa operativa. En términos experimentales, conviene monitorear el desempeño del modelo por corte o incluso valorar esquemas específicos por etapa.

Sector	Conteo	%
Manufactura	3528	17.94%
Construccion	3452	17.55%
Salud	2971	15.10%
Transporte	2524	12.83%
Retail	2074	10.54%
Agro	1936	9.84%
Tecnologia	1788	9.09%
Servicios	1398	7.11%

Tabla 6. Distribución de sectores en el dataset de features.

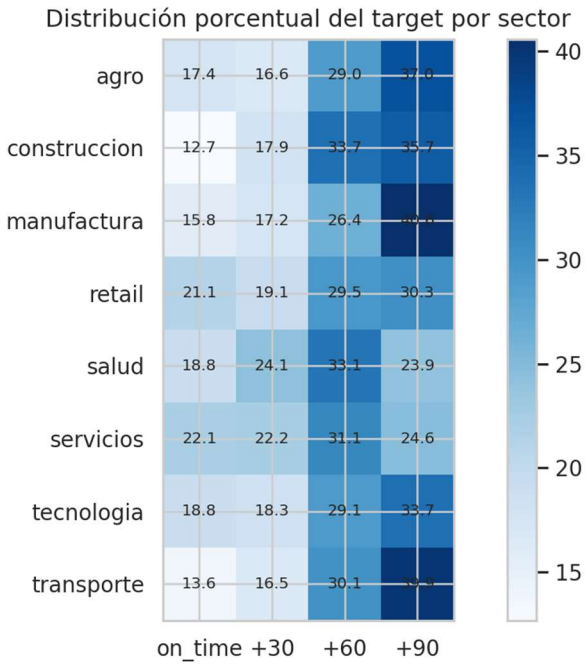

Figura 5. Distribución porcentual del target por sector.

La cartera se concentra principalmente en manufactura (17.94%), construcción (17.55%) y salud (15.10%). A nivel descriptivo, manufactura y transporte muestran mayor proporción relativa de `+90`, mientras que salud y servicios presentan una mezcla más balanceada. Estos patrones sugieren que el sector sí podría aportar señal, aunque su interpretación final debe validarse con modelado controlado.

7. Detección de valores atípicos (outliers)

Variable	% IQR	% Mod. Z
tasa_contacto_cliente	8.12%	6.18%
monto	7.88%	13.85%
num_promesas_rotas	4.83%	15.07%
num_no_contesta_cons	4.66%	0.00%
dias_desde_ultima_gestion	3.90%	5.19%
moras_consecutivas	3.41%	0.00%
promesas_total	2.75%	2.75%
ratio_monto	1.48%	0.93%
monto_promedio_hist	0.99%	13.27%
mora_ultimo_tramo	0.41%	0.41%

Tabla 7. Variables con mayor proporción de outliers.

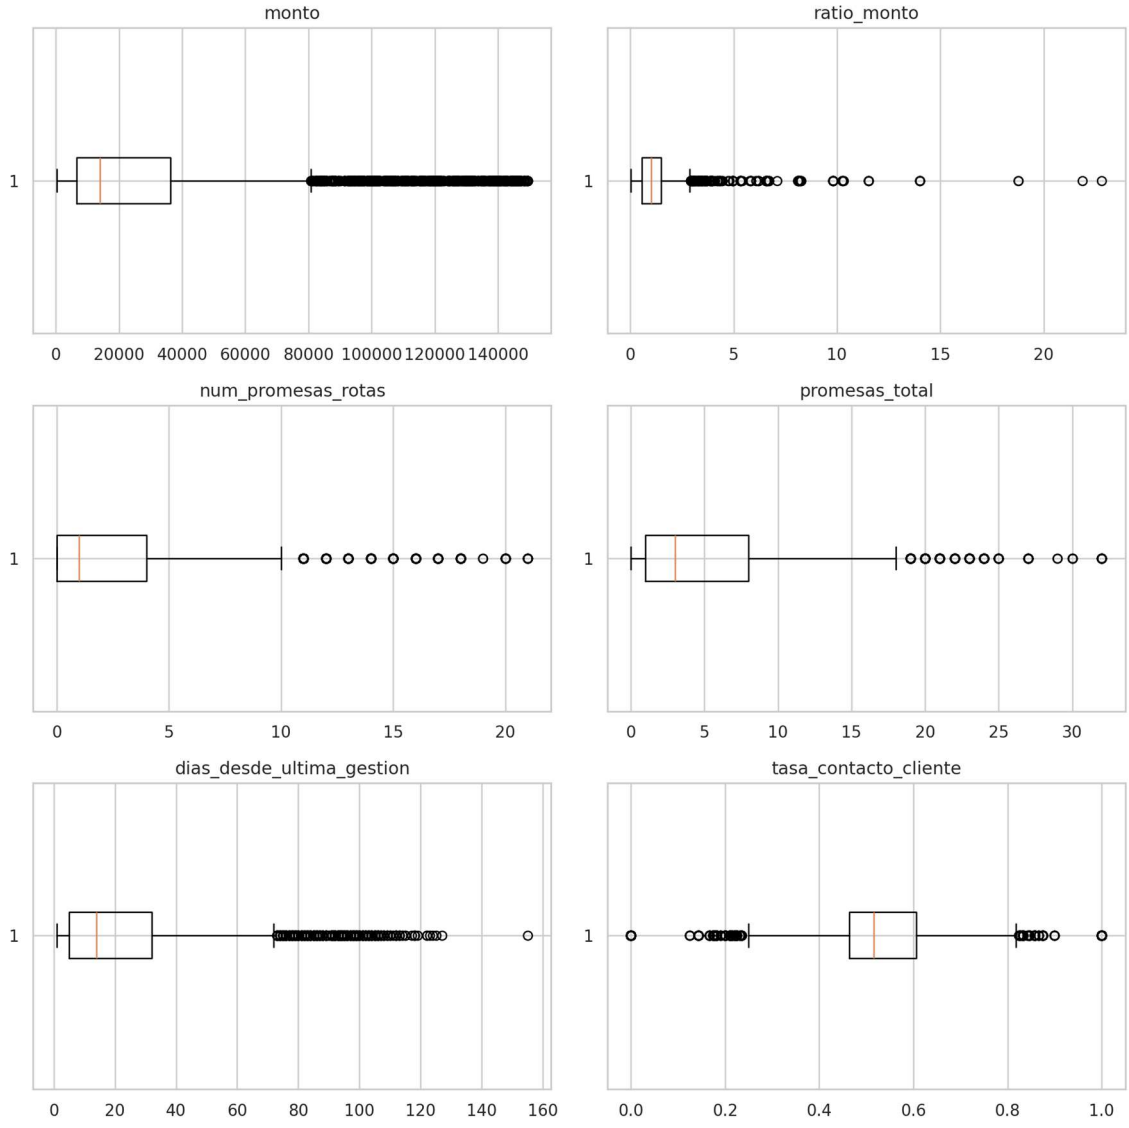

Figura 6. Boxplots de variables seleccionadas para revisión de outliers.

Aplicando IQR y modified z-score sobre variables no binarias, las mayores proporciones de atípicos se observan en `tasa_contacto_cliente` (8.12% por IQR), `monto` (7.88%) y `num_promesas_rotas` (4.83%). El método robusto intensifica especialmente la señal en `num_promesas_rotas` (15.07%) y `monto` (13.85%), lo que confirma la presencia de colas pronunciadas y observaciones extremas de negocio.

Desde la perspectiva operativa, estos valores no deben eliminarse automáticamente. En cobranzas, un monto extraordinariamente alto o una secuencia inusualmente extensa de promesas incumplidas puede representar precisamente el tipo de caso crítico que el modelo debe aprender a identificar. Una estrategia más adecuada sería usar transformaciones robustas o logarítmicas cuando el algoritmo lo requiera.

8. Correlaciones y redundancias

Variable 1	Variable 2	Rho Spearman	|Rho|
num_corte	num_gestiones_factura	1.000	1.000
num_corte	dias_hasta_vence	-0.920	0.920
num_gestiones_factura	dias_hasta_vence	-0.920	0.920
num_promesas_rotas	promesas_total	0.907	0.907
mora_promedio_hist	tasa_cumplimiento	-0.906	0.906
dias_desde_emision	dias_hasta_vence	-0.901	0.901
mora_promedio_hist	mora_ultimo_tramo	0.888	0.888
num_corte	dias_desde_emision	0.887	0.887
num_gestiones_factura	dias_desde_emision	0.887	0.887
mora_ultimo_tramo	tasa_cumplimiento	-0.833	0.833
num_promesas_rotas	tasa_cumpl_promesas	-0.816	0.816
num_facturas_prev	promesas_total	0.798	0.798

Tabla 8. Principales correlaciones de Spearman.

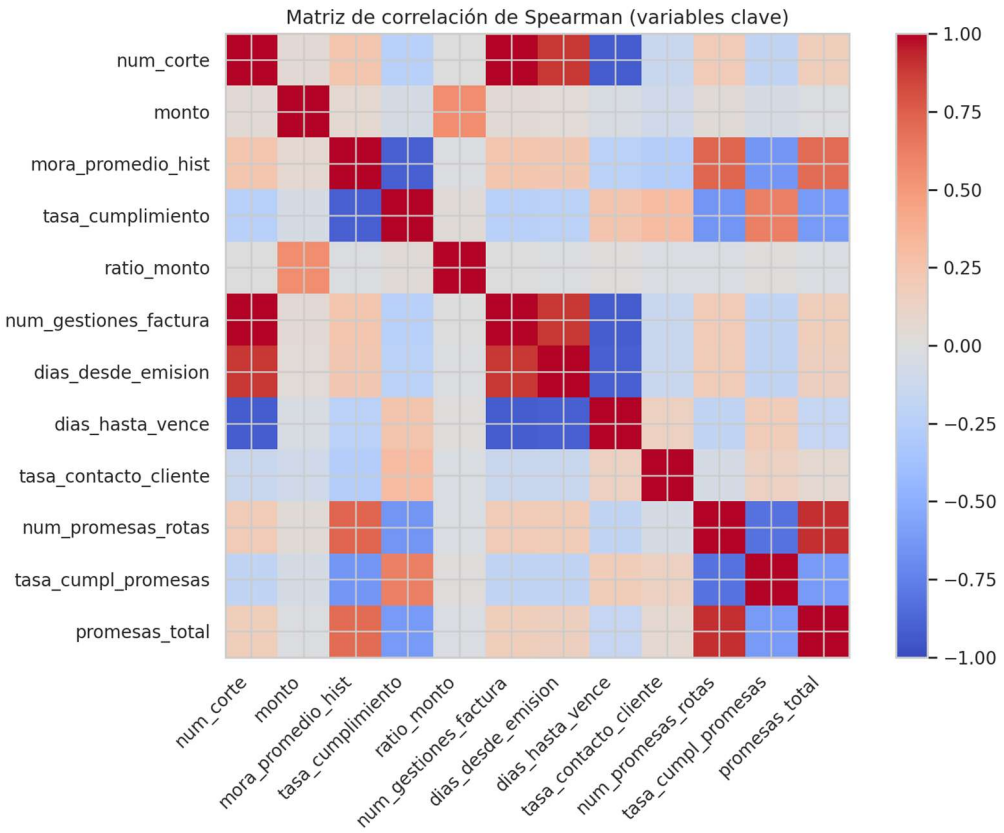

Figura 7. Matriz de correlación de variables clave.

La matriz de correlación permite distinguir tres tipos de relaciones. Primero, redundancias determinísticas: `num_corte` y `num_gestiones_factura` son idénticas ($\rho = 1.000$), mientras que `dias_hasta_vence` depende exactamente de `condicion_dias` y `dias_desde_emision`. Segundo, un bloque histórico donde `mora_promedio_hist`, `mora_ultimo_tramo` y `tasa_cumplimiento` aparecen fuertemente relacionados. Tercero, un bloque de promesas donde `num_promesas_rotas`, `promesas_total` y `tasa_cumpl_promesas` comparten información de comportamiento.

En modelos basados en árboles, esta redundancia no suele impedir el aprendizaje, pero sí puede dificultar interpretabilidad y estabilidad de la importancia de variables. En Regresión Logística, K-Means o DBSCAN, en cambio, estas dependencias sí pueden resultar problemáticas. Por ello, se recomienda revisar eliminación o consolidación de variables redundantes antes del entrenamiento.

9. Análisis bivariado orientado al negocio

Target	Monto mediana	Mora hist. mediana	Gestiones medianas	Tasa contacto mediana	Promesas rotas mediana	Cumpl. promesas mediana	Promesas totales mediana
on_time	11895.64	2.92	0.0	0.58	0.0	1.0	1.0
30	11921.53	16.44	1.0	0.54	1.0	0.67	3.0
60	13934.21	22.5	2.0	0.51	2.0	0.5	4.0
90	17528.47	34.06	4.0	0.5	2.0	0.44	5.0

Tabla 9. Medianas por clase objetivo en variables de negocio.

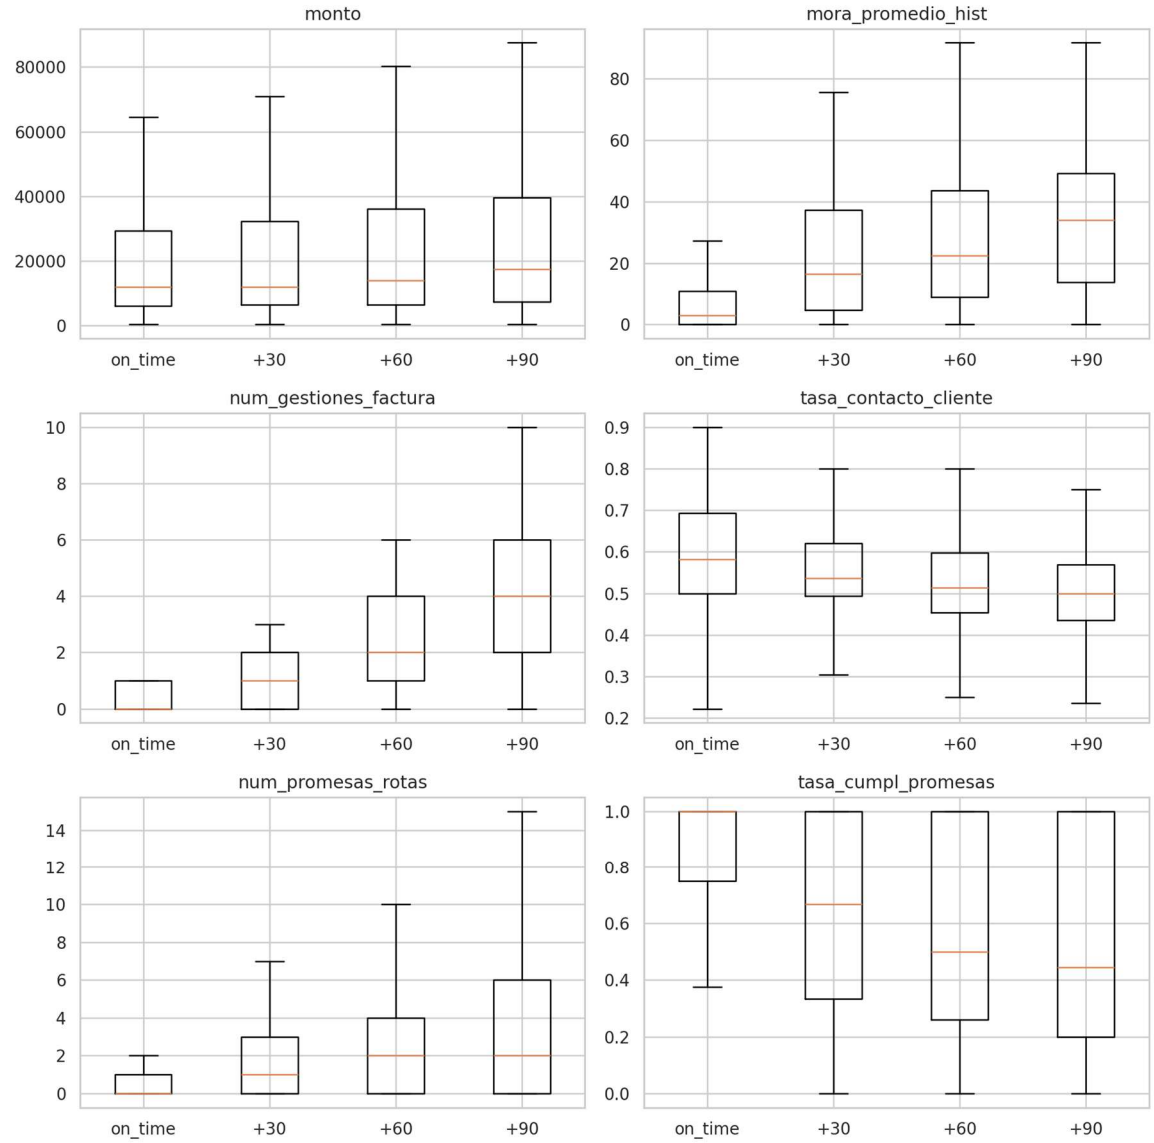

Figura 8. Boxplots por clase objetivo en variables seleccionadas.

Los contrastes por clase muestran un patrón monotónico y coherente con el problema de negocio. La mediana de `mora_promedio_hist` pasa de 2.92 días en `on_time` a 34.06 en `+90`; la mediana de `num_gestiones_factura` crece de 0 a 4; y la mediana de `promesas_total` sube de 1 a 5 entre esos mismos extremos.

En paralelo, la `tasa_cumpl_promesas` disminuye de 1.00 en `on_time` a 0.44 en `+90`, mientras que `tasa_contacto_cliente` desciende de 0.58 a 0.50. Esto sugiere que el riesgo severo no solo está asociado con un peor historial de mora, sino también con fricción operacional: más promesas, más promesas rotas y contacto relativamente menos efectivo.

La variable `tiene_disputa_activa` también aporta señal descriptiva fuerte: entre los casos con disputa activa, 50.7% pertenece a `+90` y apenas 2.4% a `on_time`. Asimismo, la presencia de garantía parece asociarse a menor severidad relativa: los registros con `tiene_garantia = 1` concentran más `on_time` (29.8%) y menos `+90` (21.8%) que aquellos sin garantía.

Las pruebas no paramétricas de Kruskal-Wallis refuerzan la diferenciación entre clases: las variables revisadas presentan diferencias estadísticamente significativas entre grupos, con especial intensidad en `num_gestiones_factura`, `mora_promedio_hist`, `num_promesas_rotas` y `tasa_cumpl_promesas`.

10. Hallazgos clave del EDA

El dataset `features_ml.csv` está estructuralmente sano: no presenta duplicados, valores fuera de rango ni problemas críticos de integridad.

Los únicos faltantes son estructurales y coherentes con los cortes 0, por lo que deben tratarse como ausencia informativa y no como error.

La composición del target cambia materialmente cuando se analiza por filas frente a facturas únicas; esto es inherente al scoring dinámico y debe explicitarse en la fase experimental.

Existen redundancias fuertes, incluidas dos relaciones determinísticas (`num_corte` = `num_gestiones_factura`; `dias_hasta_vence` = `condicion_dias - dias_desde_emision`).

Las variables históricas de mora, promesas y gestiones muestran una separación descriptiva clara entre `on_time`, `+30`, `+60` y `+90`.

Los outliers observados son plausibles desde negocio y, salvo evidencia de error, deben preservarse para no perder señal de riesgo.

11. Recomendaciones previas al modelado

- Particionar entrenamiento y prueba por `factura_id`, nunca por fila, para evitar fuga entre cortes de una misma factura.
- Revisar eliminación o consolidación de variables redundantes antes de entrenar Regresión Logística, K-Means o DBSCAN.
- Mantener un tratamiento explícito para los nulos del corte 0: indicador de ausencia, imputación lógica o categoría separada.
- Evaluar transformaciones robustas o `log1p` en variables con cola larga como `monto`, `ratio_monto`, `promesas_total` y `num_promesas_rotas`.
- Recodificar `ultimo_resultado_enc` como categórica si se utilizará en modelos sensibles a pseudo-ordinalidad.
- Reportar métricas sensibles al desbalance, especialmente F1-macro, recall por clase y balanced accuracy.
- Monitorear desempeño por etapa (`num_corte`) o por escenario operativo, dado el cambio de composición del target conforme avanzan las gestiones.

12. Anexo técnico breve

Hallazgo	Implicación	Acción sugerida
Nulos estructurales en corte 0	`dias_desde_ultima_gestion` y `ultimo_resultado_enc` no existen antes de la primera gestión	Crear indicador o imputar con lógica de ausencia
Redundancia determinística 1	`num_corte` = `num_gestiones_factura`	Conservar solo una de las dos en modelos sensibles a colinealidad
Redundancia determinística 2	`dias_hasta_vence` = `condicion_dias` - `dias_desde_emision`	Evitar usar simultáneamente las tres variables
Codificación potencialmente ordinal	`ultimo_resultado_enc` usa enteros 0–8	Evaluar one-hot encoding o codificación categórica explícita

Tabla 10. Resumen técnico de ajustes recomendados para preprocessing.

Referencias

Gareth James, D. W. (2021). Gareth James, Daniela Witten, Trevor Hastie y Robert Tibshirani. *Springer, New York, NY*.

He, H., & Garcia., E. A. (2009). Learning from Imbalanced Data. *IEEE Transactions on Knowledge and Data Engineering*.

Kuhn, M., & Johnson, K. (2019). Feature Engineering and Selection: A Practical Approach for Predictive Models. *Chapman & Hall/CRC Data Science Series, CRC Press, Boca Raton, Florida*.

Tukey, J. W. (1977). Exploratory Data Analysis. *Addison-Wesley Publishing Company, Reading, Massachusetts*.