MAESTRIA EN INTELIGENCIA ARTIFICIAL

MATERIA

PROYECTO INTEGRADOR DE INTELIGENCIA ARTIFICIAL

DOCENTE ACADEMICO

ALEXANDRA JACQUELINE ARCINIEGAS CORAL

ALUMNOS:

ROMMEL GREGORY PACHECO FLORES

KEVIN BILL UBE ALVARO

TEMA:

EVALUACIÓN DE MODELO IA

17-04-2026

PERIODO LECTIVO

2025-2026

1. Introducción

La priorización de cobranzas es un problema de decisión donde no basta con estimar quién pagará tarde. El valor real del modelo depende de si mejora de forma tangible frente a soluciones simples, si mantiene un comportamiento suficientemente estable fuera de entrenamiento y si evita amplificar diferencias operativas injustificadas entre grupos de clientes o facturas. En un contexto empresarial, un sistema de riesgo que solo optimiza una métrica global pero ignora sesgos, sobreajuste o restricciones de implementación puede generar intervenciones poco eficientes, poco transparentes o incluso contraproducentes (James, Witten, Hastie, Tibshirani, & Jonathan, 2023) (Suresh & Guttag, 2021).

El proyecto se diseñó como un sistema híbrido para empresas que venden a crédito. Su primer componente predice la clase de mora por factura, su segundo componente segmenta clientes según comportamiento histórico y una tercera capa traduce ambas salidas en acciones operativas. Esta arquitectura exige un informe integrador porque la evaluación académica no puede limitarse a mostrar un modelo entrenado. Debe demostrar valor comparativo, consistencia metodológica, conciencia ética y capacidad de generalización.

Con ese propósito, el presente documento articula tres tareas en un solo análisis. Primero, realiza un benchmarking frente a líneas base simples, referencias académicas y plataformas comerciales. Luego audita el modelo propuesto desde la perspectiva del sesgo algorítmico. Finalmente, examina señales de overfitting y underfitting mediante curvas de aprendizaje y brechas entre entrenamiento y prueba. La intención no es defender de forma acrítica un algoritmo, sino sostener una decisión metodológica bien argumentada y útil para el dominio de cobranzas.

2. Contexto técnico y metodológico del modelo evaluado

El dataset principal del proyecto, features_ml.csv, contiene 19,671 filas, 36 columnas, 5,338 facturas únicas y 200 clientes. La unidad analítica no es la factura única, sino el corte de scoring por factura. En consecuencia, una misma factura puede generar varias observaciones a lo largo del proceso de cobranza. Esta estructura es útil porque captura la evolución temporal del caso, pero también introduce un riesgo metodológico evidente: si la partición se realiza por fila, el modelo podría ver en entrenamiento y prueba información de la misma factura. Para evitar ese

leakage, la partición se efectuó por factura_id, dejando 4,270 facturas para entrenamiento y 1,068 para prueba (Kaufman, Rosset, Perlich, & Stitelman., 2012)

La fase de preparación previa mostró que la base está estructuralmente sana, sin duplicados exactos ni duplicados por factura_id + num_corte. También confirmó la existencia de nulos estructurales en dias_desde_ultima_gestion y ultimo_resultado_enc, ligados a cortes sin gestión previa, así como outliers plausibles de negocio en monto, ratio_monto, promesas_total y num_promesas_rotas. Estas características justifican una evaluación basada en métricas robustas al desbalance y sensible a la estructura del problema (He & Garcia, 2009).

En este escenario, accuracy simple es insuficiente como criterio rector. Por esa razón se priorizaron F1-macro, recall macro, balanced accuracy y AUC multiclase, complementadas con análisis de brecha entre entrenamiento y prueba. F1-macro es especialmente valiosa porque promedia el rendimiento entre clases sin dejar que las clases más frecuentes dominen la lectura. AUC multiclase añade una visión de capacidad de ranking. La brecha train-test ayuda a distinguir entre rendimiento aparente y generalización real (He & Garcia, 2009); (James, Witten, Hastie, Tibshirani, & Jonathan, 2023).

La arquitectura global del proyecto conserva como diseño final un sistema híbrido compuesto por XGBoost para clasificación multiclase, K-Means para segmentación conductual y reglas de negocio para la priorización final. No obstante, el workshop de evaluación exigió contrastar esa elección con alternativas simples y con otros modelos competitivos. Por ello, el benchmarking incluye DummyClassifier por clase mayoritaria, DummyClassifier estratificado, Regresión Logística Multinomial, Random Forest y XGBoost (Cox., 1972) ; (Breiman, 2001); (Chen & Guestrin, 2016); (MacQueen, 1967).

Tabla 1

Resumen del contexto analítico y del esquema de validación

0	1
Registros analíticos	19,671 filas
Variables originales	36 columnas
Facturas únicas	5,338
Clientes únicos	200
Dataset preparado	43 columnas tras ingeniería de variables
Partición externa	4,270 facturas en train y 1,068 en test
Filas por partición	15,735 en train y 3,936 en test
Unidad de evaluación	Corte de scoring por factura

Nota. Elaboración propia a partir del dataset oficial del proyecto y de la corrida reproducible de evaluación.

3. Benchmarking comparativo

3.1 Propósito y criterios de comparación

El benchmarking se planteó como una evaluación multinivel. El primer nivel responde a una pregunta básica pero ineludible: cuánto mejora el sistema frente a soluciones triviales. El segundo nivel contrasta el proyecto con literatura relevante en riesgo de crédito y default forecasting. El tercer nivel lo ubica frente a alternativas comerciales para determinar si una solución propia sigue teniendo sentido frente a plataformas administradas.

Los criterios de contraste fueron desempeño predictivo, generalización, interpretabilidad, complejidad técnica, costo de implementación, personalización, explicabilidad, utilidad operativa y escalabilidad. Ningún criterio por sí solo basta. En datos tabulares financieros, el mejor modelo no siempre es el de mayor F1 puntual. También importa si la mejora es estable, si las salidas son accionables y si la solución puede integrarse con reglas de negocio sin quedar encapsulada en una caja negra difícil de auditar (Lessmann, Baesens, Seow, & Thomas., 2015); (James, Witten, Hastie, Tibshirani, & Jonathan, 2023).

3.2 Benchmark contra modelos baseline

La comparación empírica se ejecutó sobre el split oficial por factura_id. Los dos dummies cumplen funciones distintas. El clasificador por clase mayoritaria representa el mínimo esfuerzo predictivo. El clasificador estratificado conserva la distribución de clases de manera aleatoria y sirve como referencia ligeramente menos trivial. La Regresión Logística Multinomial se incorporó como baseline interpretable. Sobre esa base se compararon dos modelos de ensamble, Random Forest y XGBoost (Cox., 1972) ; (Breiman, 2001) ; (Chen & Guestrin, 2016).

Tabla 2

Comparación de líneas base y modelos candidatos sobre el conjunto de prueba

Modelo	Accuracy test	Balanced accuracy	Precision macro	Recall macro	F1-macro	AUC multiclase	Brecha F1
Random Forest	0.5676	0.5904	0.564	0.5904	0.5699	0.819	0.3876
Regresión Logística	0.5668	0.5996	0.5617	0.5996	0.5695	0.8135	0.012
XGBoost	0.5567	0.577	0.5482	0.577	0.5542	0.8163	0.1545
Dummy estratificado	0.2675	0.2468	0.2471	0.2468	0.2468	0.4964	0.0028
Dummy mayoritario	0.3305	0.25	0.0826	0.25	0.1242	0.5	0.0031

Nota. Métricas calculadas sobre el split oficial por factura_id. La brecha F1 corresponde a la diferencia absoluta entre entrenamiento y prueba.

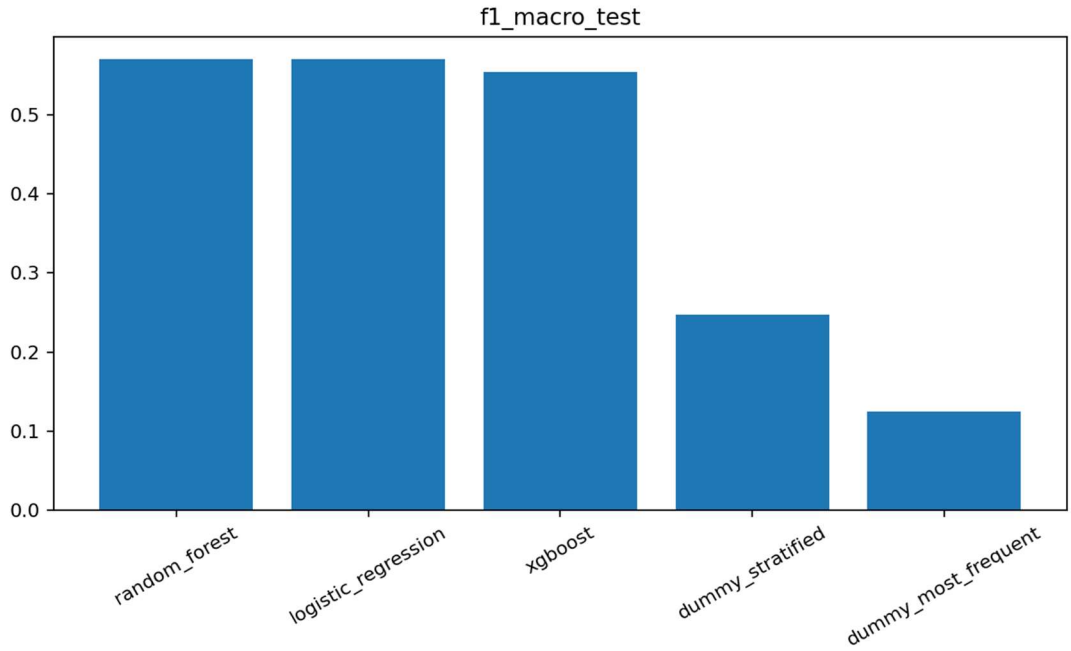

Figura 1

Comparación del F1-macro en el conjunto de prueba

Nota. Elaboración propia a partir de la corrida oficial del workshop.

Los resultados muestran una primera conclusión clara. Todos los modelos sustantivos superan de forma amplia a las líneas base triviales. XGBoost mejora el F1-macro del dummy mayoritario en 0.430 puntos absolutos y el del dummy estratificado en 0.307 puntos. En ese sentido, la complejidad adicional sí se justifica frente a referencias simples. Sin embargo, el benchmarking también revela que la comparación relevante ya no es solo contra los dummies, sino contra una línea base interpretable bien ajustada.

Random Forest obtuvo el mayor F1-macro de prueba, 0.5699, pero con una brecha train-test de 0.3876. Regresión Logística quedó prácticamente empatada en F1-macro, 0.5695, y mostró la mejor generalización, con una brecha de solo 0.0120. XGBoost registró un F1-macro ligeramente inferior, 0.5542, pero mantuvo AUC multiclase competitivo, 0.8163, y una brecha

claramente menor que la de Random Forest. Esta combinación obliga a una lectura crítica. El mejor valor puntual de F1 no coincide con el mejor equilibrio metodológico.

Desde una lógica estrictamente predictiva de corto plazo, Random Forest podría considerarse ganador del workshop. No obstante, si el objetivo es sostener un sistema híbrido que combine riesgo por factura, segmentación de clientes y reglas de negocio, la decisión no puede basarse solo en una diferencia marginal de F1. XGBoost sigue siendo defendible como modelo principal porque preserva mejor el valor de las interacciones no lineales, ofrece una estructura compatible con explicabilidad post hoc y se alinea con la selección previa del proyecto. La Regresión Logística, por su parte, conserva un rol importante como benchmark interpretable y como referencia de estabilidad (Breiman, 2001); (Chen & Guestrin, 2016); (James, Witten, Hastie, Tibshirani, & Jonathan, 2023).

3.3 Benchmark contra el estado del arte

La comparación con el estado del arte debe hacerse con prudencia. La mayor parte de la literatura en crédito trabaja con problemas binarios de default o credit scoring al nivel de préstamo o solicitante, mientras que este proyecto trabaja con una clasificación multiclase, temporal y por factura. Por ello, una comparación directa de valores de F1 o AUC puede inducir conclusiones erróneas. Lo defendible es comparar familias metodológicas, escala del problema, tipo de variable objetivo y criterios de evaluación (Lessmann, Baesens, Seow, & Thomas., 2015); (Barbaglia, Manzan, & Tosetti, 2023).

Tabla 3

Referencias académicas de contraste con el estado del arte

Referencia	Dominio	Escala o tipo de datos	Modelo o enfoque	Métrica reportada	Comparabilidad	Observación crítica
Lessmann et al. (2015)	Benchmark multibase en credit scoring	Múltiples datasets de scoring	Comparación amplia de clasificadores	Exactitud predictiva y medidas de ranking	Media	Problema mayormente binario y al nivel de scorecard; útil como referencia metodológica, no como benchmark numérico directo
Barbaglia et al. (2023)	Default hipotecario en Europa	12 millones de hipotecas	ML vs. regresión logística	Desempeño predictivo relativo al default	Media-baja	Escala masiva y default binario; comparable en espíritu pero no en estructura multiclase por cortes
Liu et al. (2021)	Credit risk assessment con cruce automático de variables	Datos tabulares financieros	Cross features + LR interpretable	Rendimiento con énfasis en interpretabilidad	Media	Se acerca al problema tabular financiero y al dilema entre desempeño e interpretabilidad

Nota. La columna de comparabilidad evalúa similitud metodológica y no equivalencia directa de resultados. Fuente de referencias: (Lessmann, Baesens, Seow, & Thomas., 2015); (Barbaglia, Manzan, & Tosetti, 2023); (Liu, Fan, & Xia, 2021).

(Lessmann, Baesens, Seow, & Thomas., 2015) propusieron un benchmark de referencia para credit scoring y mostraron la importancia de comparar familias de clasificadores bajo múltiples medidas de precisión y ranking. Su aporte no consiste solo en identificar un algoritmo ganador,

sino en demostrar que la evaluación rigurosa requiere múltiples datasets, múltiples métricas y análisis de relevancia gerencial. Ese criterio es totalmente pertinente aquí, aunque el problema del proyecto sea más complejo en términos operativos por su formulación multiclase y temporal (Lessmann, Baesens, Seow, & Thomas., 2015).

Barbaglia, Manzan y Tosetti analizaron default hipotecario europeo con un volumen de datos muy superior al del presente proyecto y reportaron que varios algoritmos de machine learning superan a la regresión logística en capacidad predictiva. La similitud con este trabajo radica en el contraste entre modelos lineales y no lineales bajo datos financieros reales. La diferencia clave es que su tarea es binaria y a nivel de préstamo, mientras que este proyecto exige separar cuatro estados finales de mora en varios cortes de una misma factura. Esa diferencia tiende a volver más difícil la tarea actual (Barbaglia, Manzan, & Tosetti, 2023).

Liu et al. representan una referencia útil para la discusión entre desempeño e interpretabilidad en riesgo crediticio tabular. Su propuesta de extraer cruces de variables para luego alimentar una logística mejorada muestra que la frontera entre modelo interpretable y modelo potente no siempre es absoluta. Esta lectura es relevante porque explica por qué la Regresión Logística de este proyecto logró un F1-macro competitivo. No obstante, también confirma que la no linealidad y la interacción entre señales históricas y operativas siguen siendo un argumento válido para conservar XGBoost como candidato principal del sistema (Liu, Fan, & Xia, 2021).

En síntesis, el proyecto no puede afirmar que esté numéricamente al nivel del estado del arte porque las tareas, escalas y unidades analíticas no son equivalentes. Lo que sí puede sostener es que sigue una línea metodológica consistente con la literatura contemporánea en riesgo crediticio. El uso de ensambles sobre datos tabulares, la comparación contra logística y la atención al desbalance y a la interpretabilidad encajan con las discusiones dominantes del campo (Lessmann, Baesens, Seow, & Thomas., 2015); (Barbaglia, Manzan, & Tosetti, 2023); (Liu, Fan, & Xia, 2021).

3.4 Benchmark contra modelos comerciales

No se ejecutó una prueba empírica directa contra APIs comerciales. Por tanto, esta comparación no pretende simular resultados inexistentes. Lo que se presenta es una evaluación metodológica y funcional frente a tres plataformas administradas que, en principio, podrían cubrir parte del

problema: Google Vertex AI, Azure Machine Learning y Amazon SageMaker (Google Cloud, 2026; Microsoft, 2025, 2026; Amazon Web Services, n.d.-a, n.d.-b, n.d.-c).

Tabla 4

Comparación funcional frente a alternativas comerciales

Opción	Fortaleza principal	Limitación principal	Adecuación al caso	Explicabilidad y auditoría	Privacidad y dependencia
Modelo propio XGBoost + K-Means	Máxima personalización, control completo del split por factura_id y ajuste fino de reglas de negocio	El equipo debe sostener código, monitoreo y gobierno del modelo	Alta, porque el pipeline puede diseñarse exactamente para cortes por factura y segmentación por cliente	Alta, con trazabilidad directa y explicabilidad post hoc	Alta, al evitar dependencia cerrada y mantener el dato sensible dentro del flujo propio
Google Vertex AI	Plataforma unificada para entrenar y desplegar modelos; soporta tabular AutoML	Mayor dependencia del proveedor y costos recurrentes de entrenamiento, despliegue e inferencia	Media-alta, aunque la lógica de negocio compleja exige componentes adicionales	Media; la documentación oficial sigue ofreciendo explicaciones, pero la capacidad Vertex Explainable AI entró en deprecación en marzo de 2026	Media, condicionada a la arquitectura y gobierno cloud adoptados

Opción	Fortaleza principal	Limitación principal	Adecuación al caso	Explicabilidad y auditoría	Privacidad y dependencia
Azure Machine Learning	AutoML para clasificación tabular y tablero de Responsible AI con fairness, explicaciones y scorecard	Dependencia de ecosistema Azure y menor control nativo sobre reglas operativas muy específicas	Alta para prototipado y gobierno; media para personalización fina del caso de cobranzas	Alta, porque el tablero Responsible AI incorpora fairness, error analysis, causal analysis y contrafactuales	Media, con posibilidades sólidas de trazabilidad y cumplimiento, aunque bajo servicios administrados
Amazon SageMaker	Autopilot automatiza construcción y despliegue; Clarify aporta explicabilidad y Pipelines permite orquestación	Mayor carga de ingeniería que una solución AutoML simple y fuerte dependencia de AWS	Alta para MLOps, media para adaptación de reglas de negocio si el equipo no domina la plataforma	Media-alta, gracias a Clarify y al soporte de pipelines e inference pipelines	Media, sujeta a la estrategia de red, almacenamiento y gobierno en AWS

Nota. Comparación metodológica sin prueba empírica directa contra plataformas comerciales. Fuente conceptual: Google Cloud (2026), Microsoft (2025, 2026) y Amazon Web Services (n.d.-a, n.d.-b, n.d.-c).

Esta lectura deja una idea central. Las plataformas comerciales reducen fricción de despliegue y aportan herramientas valiosas de gobierno y monitoreo. Azure destaca por su Responsible AI dashboard y scorecard, lo que la vuelve atractiva en escenarios donde fairness y explicabilidad son prioritarias. SageMaker sobresale cuando la organización necesita orquestación robusta de pipelines y control fino del ciclo MLOps. Vertex AI mantiene ventaja como plataforma unificada de entrenamiento y despliegue, aunque para este caso pierde algo de atractivo porque su capacidad de Explainable AI entró en deprecación en marzo de 2026. Para un proyecto académico y operativo centrado en facturas, cortes temporales y reglas de cobranza, una

solución propia sigue siendo competitiva precisamente por su mayor personalización y por el control que ofrece sobre leakage, trazabilidad y traducción a reglas de negocio (Google Cloud, 2026; Microsoft, 2025, 2026; Amazon Web Services, n.d.-a, n.d.-b, n.d.-c).

3.5 Síntesis del benchmarking

El benchmarking permite una conclusión matizada. El modelo propuesto sí supera con claridad a referencias simples, por lo que no se trata de complejidad gratuita. Sin embargo, la reevaluación no valida una lectura triunfalista de XGBoost. En esta corrida concreta, Random Forest lideró en F1-macro, pero lo hizo con una señal fuerte de sobreajuste. La Regresión Logística quedó casi empatada y resultó ser el benchmark más estable. XGBoost no ganó por F1 puntual, pero sigue siendo una elección razonable para el sistema final porque combina competitividad predictiva, AUC multiclase sólido, mejor equilibrio que Random Forest y mayor congruencia con una arquitectura híbrida orientada a negocio.

La ventaja competitiva del modelo propuesto no está en dominar todos los indicadores de manera aislada, sino en mantener una combinación defendible entre precisión, capacidad de ranking, flexibilidad para capturar no linealidad y compatibilidad con la segmentación conductual del cliente. Su principal limitación sigue siendo la sensibilidad al tuning y la necesidad de fortalecer el monitoreo de cohortes. En otras palabras, el modelo es valioso, pero su conveniencia depende de acompañarlo con disciplina metodológica y no de presentarlo como una solución automática o infalible.

4. Análisis de sesgo algorítmico

4.1 Justificación

En cobranzas, el sesgo algorítmico no necesariamente aparece como discriminación directa sobre atributos protegidos clásicos. Puede emerger como una distribución desigual de errores entre segmentos operativos, niveles de exposición, historial de gestión o variables que funcionan como proxies de vulnerabilidad empresarial. Si un modelo sistemáticamente subestima el riesgo de algunos grupos y sobreestima el de otros, la asignación de recursos y la intensidad de gestión podrían volverse inequitativas o ineficientes (Hardt, Price, & Srebro, 2016) ; (Suresh & Guttag, 2021).

4.2 Identificación de variables sensibles y cuasi-sensibles

Para esta auditoría se consideraron seis agrupadores: sector, tiene_garantia, cliente_nuevo, tiene_disputa_activa, bandas de monto y bandas de intensidad de gestión. Ninguno es un atributo sensible directo en el sentido jurídico habitual, pero varios operan como variables cuasi-sensibles o como proxies de condiciones estructurales. El sector puede reflejar diferencias económicas persistentes. La presencia de garantía puede correlacionarse con tamaño o capacidad de negociación. La intensidad de gestión puede heredar decisiones históricas del propio proceso de cobranza. La disputa activa puede concentrar casos complejos donde el resultado operativo depende de factores no puramente crediticios (Suresh & Guttag, 2021).

4.3 Definición de grupos y procedimiento de auditoría

Con el fin de alinear la auditoría con el modelo finalmente recomendado, las métricas de fairness se recalcularon sobre XGBoost utilizando el conjunto de prueba oficial, los índices preservados del split por factura_id y las variables disponibles en el dataset preparado. Se calcularon accuracy, precision macro, recall macro, F1-macro, false positive rate macro one-vs-rest y false negative rate macro one-vs-rest por grupo. Además, se resumió la mayor brecha observada por variable agrupadora.

Tabla 5

Brechas máximas de desempeño por variable agrupadora en XGBoost

Variable de grupo	Brecha accuracy	Brecha F1	Brecha precision	Brecha recall
bandas_intensidad_gestion	0.1235	0.1183	0.106	0.1315
bandas_monto	0.0419	0.0267	0.0361	0.0279
cliente_nuevo	0.0308	0.0524	0.0332	0.014
sector	0.063	0.0826	0.1068	0.0772
tiene_disputa_activa	0.0341	0.0631	0.0767	0.0671

Variable de grupo	Brecha accuracy	Brecha F1	Brecha precision	Brecha recall
tiene_garantia	0.0983	0.0677	0.1013	0.0439

Nota. Las brechas se expresan como diferencia entre el valor máximo y mínimo observado entre subgrupos del conjunto de prueba.

Tabla 6

Detalle de subgrupos con mayor relevancia operativa en la auditoría de fairness

Variable	Grupo	n	Accuracy	Precision macro	Recall macro	F1-macro
tiene_garantia	0	2699	0.5258	0.5168	0.5551	0.5266
tiene_garantia	1	1237	0.6241	0.6181	0.599	0.5943
tiene_disputa_activa	0	3553	0.5533	0.5459	0.5704	0.5498
tiene_disputa_activa	1	383	0.5875	0.4691	0.6375	0.4867
bandas_intensidad_gestion	(-0.001, 0.0308]	1974	0.5035	0.4779	0.4965	0.4783
bandas_intensidad_gestion	(0.0308, 0.0495]	978	0.593	0.5761	0.628	0.593
bandas_intensidad_gestion	(0.0495, 0.25]	984	0.627	0.584	0.6271	0.5966

Nota. Se muestran los grupos con señales más visibles de disparidad o interés operativo.

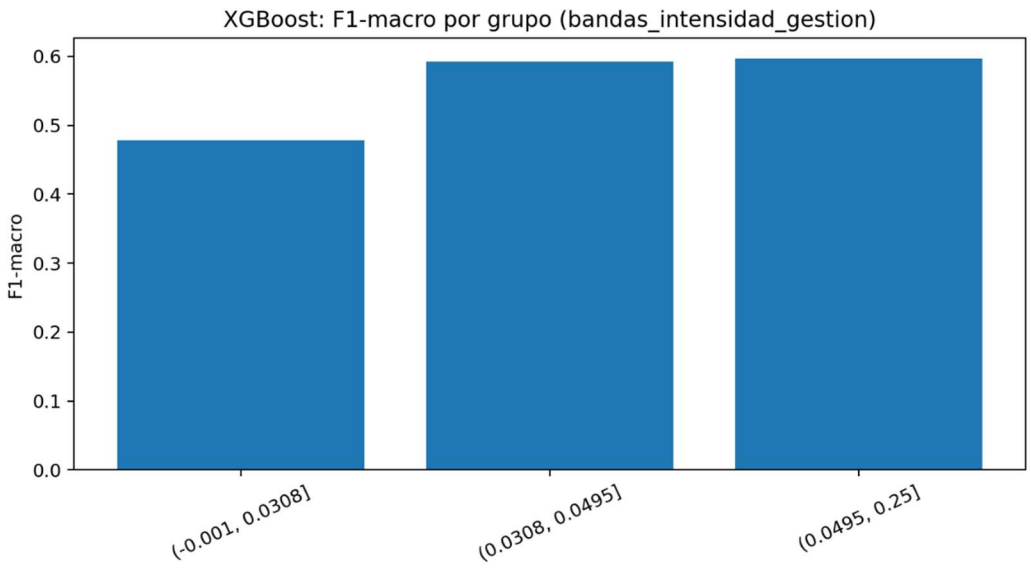

Figura 2

XGBoost: F1-macro por bandas de intensidad de gestión

Nota. La caída del desempeño en la banda de menor intensidad es una de las señales de fairness más visibles.

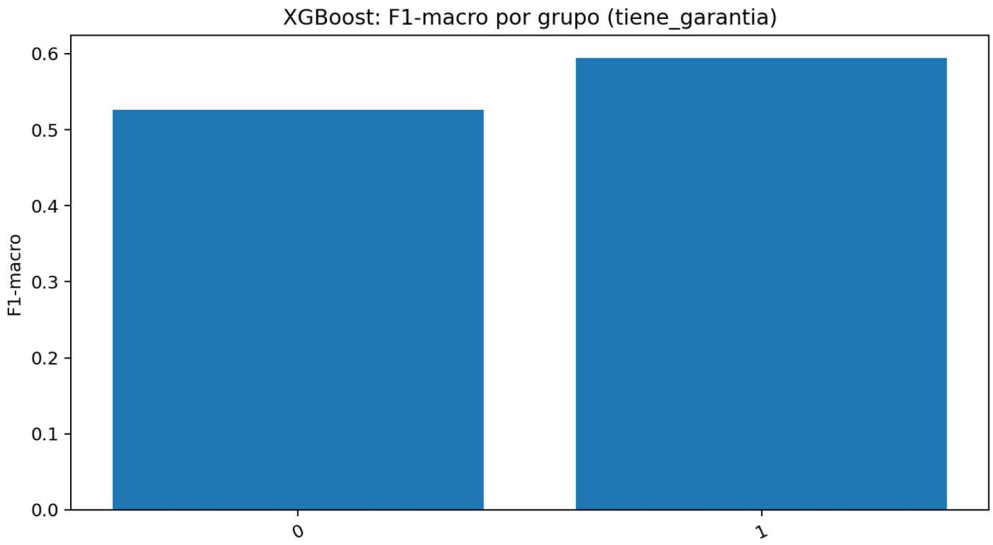

Figura 3

XGBoost: F1-macro según presencia de garantía

Nota. La diferencia entre facturas con y sin garantía sugiere un patrón operativo que debe monitorearse.

4.4 Lectura crítica de los resultados

La señal más fuerte aparece en bandas de intensidad de gestión. La brecha de recall macro alcanza 0.1315 y la de F1-macro 0.1183. El subgrupo con menor intensidad de gestión registra F1-macro de 0.4783, mientras que las bandas superiores se ubican cerca de 0.5930 y 0.5966. Esta diferencia puede interpretarse de dos maneras. Por un lado, el modelo podría estar capturando peor los casos que todavía no han recibido suficiente interacción. Por otro, la propia intensidad de gestión puede condensar información histórica sobre severidad y, en ese sentido, operar como proxy de la estrategia humana previa. En ambos casos, el riesgo no es solo estadístico. También es operativo, porque podría reforzar un ciclo donde los casos menos intervenidos permanezcan peor calibrados.

La variable tiene_garantia muestra otra diferencia relevante. El F1-macro es de 0.5266 cuando no existe garantía y de 0.5943 cuando sí existe, con una brecha de precision macro de 0.1013. Este patrón no prueba discriminación, pero sí indica que el modelo se comporta mejor sobre facturas con respaldo contractual más fuerte. Desde negocio, la lectura plausible es que la garantía simplifica la estructura de riesgo o que se asocia con perfiles menos ambiguos. Aun así, el resultado es importante porque el sistema podría terminar gestionando con menor calidad precisamente los casos más expuestos y sin respaldo adicional.

En tiene_disputa_activa aparece una señal más ambigua. El recall macro es mayor en facturas con disputa activa, pero el F1-macro cae hasta 0.4867. Esto sugiere que el modelo recupera más casos positivos en ese grupo, pero lo hace a costa de mayor ruido o menor precisión relativa. La conclusión metodológicamente correcta no es que exista un sesgo simple a favor o en contra, sino que el patrón de error cambia según el tipo de caso. Ese hallazgo merece seguimiento porque las disputas activas combinan riesgo crediticio con complejidad operativa y pueden requerir reglas diferentes.

Las diferencias por sector existen, pero son menos severas. La brecha máxima de F1-macro por sector es 0.0826, con servicios como mejor desempeño y agro y retail como segmentos más difíciles. Dado que el sector sintetiza condiciones económicas heterogéneas, esta variación resulta plausible. No constituye por sí sola evidencia de trato injusto, pero sí una alerta sobre la necesidad de revisar calibración y error por cohorte.

4.5 Reflexión ética y estrategias de mitigación

Desde una perspectiva ética, el principal riesgo del sistema no es excluir personas de un derecho fundamental, sino asignar intensidad de cobranza de manera desigual sin una justificación suficientemente transparente. En un entorno empresarial esto puede traducirse en sobreintervención sobre algunos grupos, subatención de otros, reforzamiento de sesgos históricos de gestión y debilitamiento de la legitimidad de las decisiones automatizadas (Hardt, Price, & Srebro, 2016); (Suresh & Guttag, 2021).

La mitigación debe ser concreta. Primero, conviene monitorear métricas por cohorte en producción y no solo una métrica global. Segundo, las variables proxy de historial operativo, especialmente intensidad de gestión, requieren revisión periódica para distinguir señal legítima de arrastre de decisiones humanas previas. Tercero, la priorización final debe mantenerse bajo una lógica human-in-the-loop cuando el caso combine alta incertidumbre, disputa activa o ausencia de garantía. Cuarto, la calibración de umbrales operativos puede hacerse por segmentos cuando exista una justificación de negocio explícita y documentada. Finalmente, el proyecto debe conservar una ficha de modelo que describa fuentes de datos, grupos auditados, métricas de fairness y límites de uso.

4.6 Conclusión de fairness

La auditoría no muestra evidencia concluyente de un sesgo prohibido en sentido estricto, pero sí revela diferencias prácticas que podrían afectar la equidad operativa del sistema. Las más visibles se concentran en la intensidad de gestión y en la presencia de garantía. Por ello, el uso del modelo es defendible solo si se acompaña de monitoreo de cohortes, revisión de proxies y reglas de intervención que no conviertan la predicción en una decisión automática e irreversible.

5. Diagnóstico de overfitting y underfitting

5.1 Marco conceptual breve

Overfitting aparece cuando un modelo aprende patrones demasiado específicos del entrenamiento y luego pierde capacidad para generalizar. Underfitting aparece cuando el modelo es tan simple o está tan restringido que ni siquiera aprende bien la estructura del problema. En datos tabulares financieros, ambos riesgos son plausibles. La mezcla de variables históricas, operativas, categóricas y temporales puede favorecer modelos muy flexibles, pero también

volver competitivas a soluciones más sobrias si la señal relevante es estable (James, Witten, Hastie, Tibshirani, & Jonathan, 2023).

5.2 Curvas de aprendizaje

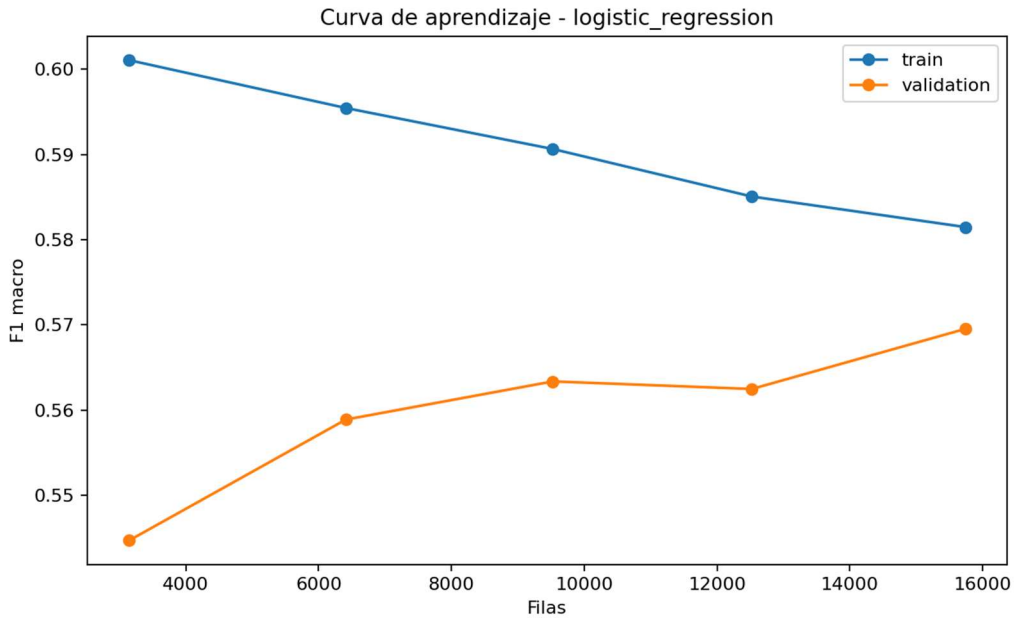

Figura 4

Curva de aprendizaje de Regresión Logística Multinomial

Nota. La cercanía entre entrenamiento y validación sugiere ajuste estable, aunque con un techo de desempeño moderado.

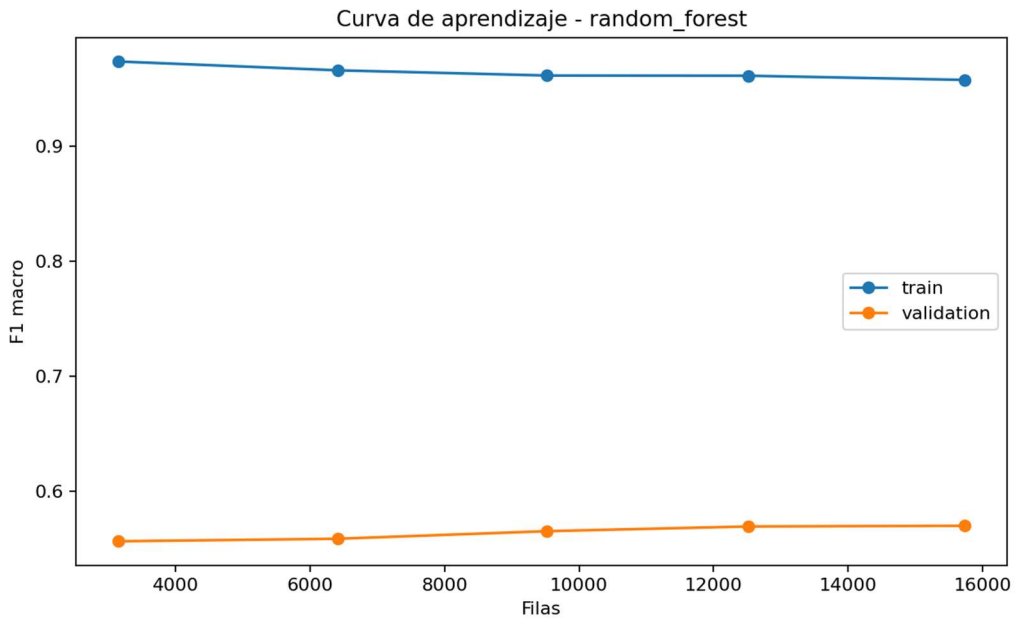

Figura 5

Curva de aprendizaje de Random Forest

Nota. La distancia entre entrenamiento y validación indica alta capacidad de memorización y sobreajuste.

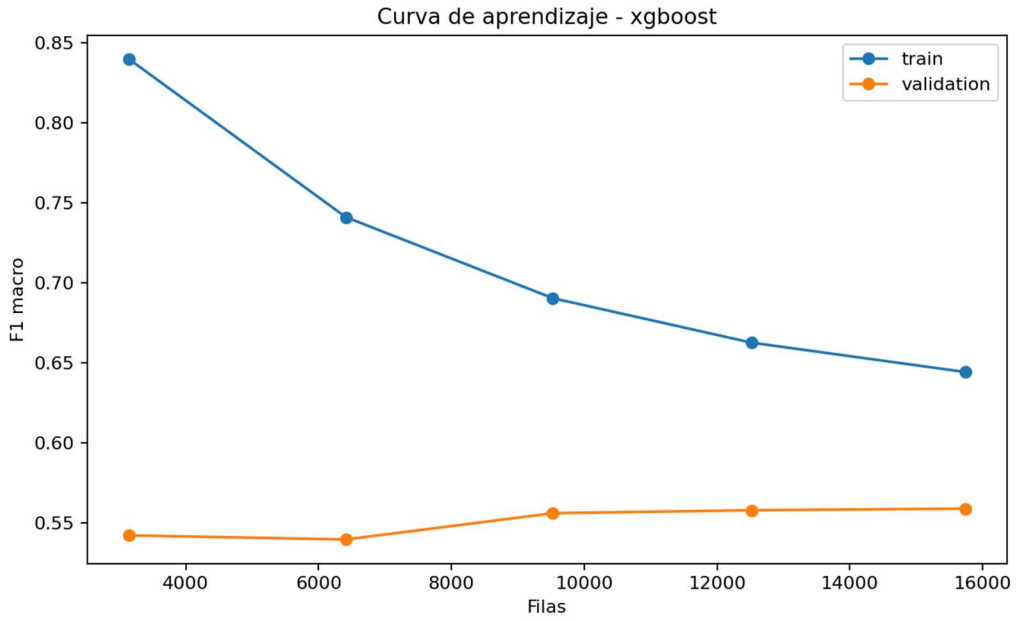

Figura 6

Curva de aprendizaje de XGBoost

Nota. El patrón muestra mejor control que Random Forest, aunque aún existe separación visible entre entrenamiento y validación.

Las curvas confirman la lectura del benchmarking. La Regresión Logística converge de manera estable y con una separación mínima entre entrenamiento y validación. Random Forest exhibe entrenamiento muy alto y validación claramente menor a lo largo de casi toda la curva. XGBoost se sitúa en una posición intermedia: aprende más señal que la logística, pero sin cerrar por completo la brecha entre entrenamiento y validación.

5.3 Comparación entrenamiento vs. prueba

Tabla 7

Brechas entre entrenamiento y prueba

Modelo	F1 train	F1 test	Brecha F1	Accuracy train	Accuracy test	Brecha accuracy
Random Forest	0.9575	0.5699	0.3876	0.9625	0.5676	0.3949
Regresión Logística	0.5815	0.5695	0.012	0.5813	0.5668	0.0144
XGBoost	0.7087	0.5542	0.1545	0.7251	0.5567	0.1685
Dummy estratificado	0.2496	0.2468	0.0028	0.2707	0.2675	0.0031
Dummy mayoritario	0.1273	0.1242	0.0031	0.3416	0.3305	0.0111

Nota. Las brechas elevadas son una señal de riesgo de sobreajuste; las brechas mínimas con bajo rendimiento son compatibles con underfitting.

La Regresión Logística es el modelo con mejor generalización en sentido estricto. Su F1-macro cae apenas 0.0120 puntos entre entrenamiento y prueba. Esto sugiere que la complejidad lineal es suficiente para capturar una parte importante de la estructura del problema. Sin embargo, ese buen comportamiento no implica que sea la mejor alternativa final, porque su capacidad para explotar interacciones no lineales sigue siendo limitada.

Random Forest muestra el caso más claro de overfitting. Su F1-macro de entrenamiento es 0.9575 y el de prueba cae a 0.5699. La brecha de 0.3876 es demasiado alta para considerar el modelo como opción robusta de despliegue sin ajustes adicionales. El hecho de que aun con esa brecha logre el mayor F1 de prueba indica que hay señal poderosa, pero también que una parte del rendimiento observado en entrenamiento no es transferible.

XGBoost conserva una situación intermedia. Su F1-macro pasa de 0.7087 en entrenamiento a 0.5542 en prueba, con brecha de 0.1545. Esto sigue siendo una señal de sobreajuste, pero mucho más contenida que en Random Forest. En términos prácticos, XGBoost parece balancear mejor capacidad de aprendizaje y control de varianza, aunque todavía requiere tuning adicional.

5.4 Causas probables y estrategias de mejora

Existen varias causas plausibles del patrón observado. La primera es la propia complejidad del problema, que combina cortes repetidos por factura con variables históricas y operativas. La segunda es el desbalance, que cambia según se mire por fila o por factura. La tercera es la presencia de redundancias y proxies temporales fuertes, que pueden amplificar la capacidad de memorización de modelos basados en árboles. La cuarta es que algunos outliers plausibles de negocio, aunque útiles, también incrementan la dificultad de regularizar el aprendizaje (He & Garcia, 2009); (Kaufman, Rosset, Perlich, & Stitelman., 2012).

Las mejoras recomendadas siguen una lógica de prioridad. En XGBoost, conviene reforzar regularización, revisar profundidad máxima, min_child_weight y learning rate, y utilizar early stopping sobre una validación verdaderamente externa por factura. En Random Forest, es prioritario limitar profundidad, ajustar max_features y aumentar el control sobre hojas mínimas. En ambos modelos, la eliminación o consolidación de variables redundantes puede reducir la memorización de ruido. También resulta aconsejable revisar calibración de probabilidades y complementar la evaluación con validación temporal o por cohortes si el calendario operativo lo permite (James, Witten, Hastie, Tibshirani, & Jonathan, 2023); (Kaufman, Rosset, Perlich, & Stitelman., 2012).

La conclusión del diagnóstico es clara. No hay evidencia de underfitting en los modelos sustantivos. Sí existe una señal fuerte de overfitting en Random Forest y una señal moderada en XGBoost. La Regresión Logística generaliza mejor, pero a costa de menor riqueza estructural. Por tanto, el sistema puede considerarse metodológicamente válido siempre que la selección

final del modelo no ignore estas diferencias y que el despliegue incluya control explícito de generalización.

6. Discusión integrada

La integración de benchmarking, fairness y generalización evita una lectura simplista del problema. Si el análisis se limitara a comparar F1-macro en prueba, Random Forest sería la respuesta inmediata. Si solo se privilegiara estabilidad, la Regresión Logística sería la elección obvia. Si el foco se redujera a flexibilidad e integración con el sistema híbrido, XGBoost seguiría siendo el candidato más natural. El valor del presente informe es precisamente mostrar que la decisión correcta no surge de una métrica aislada.

Desde el punto de vista del benchmarking, el proyecto demuestra valor real frente a modelos triviales. Desde el punto de vista de generalización, la evidencia obliga a desconfiar de Random Forest como solución final sin regularización adicional. Desde el punto de vista de fairness, el modelo propuesto es utilizable, pero no debería desplegarse sin monitoreo por cohortes, especialmente en intensidad de gestión y garantía.

Bajo esa lectura integrada, la elección más defendible para el sistema completo sigue siendo XGBoost para clasificación, K-Means para segmentación y una capa de reglas de negocio para la priorización final. Esta elección reconoce que XGBoost no ganó todos los indicadores en la corrida oficial, pero sí mantiene un equilibrio más razonable entre capacidad predictiva, flexibilidad para relaciones no lineales, compatibilidad con el diseño híbrido y margen de mejora mediante tuning. La recomendación no oculta la evidencia. La incorpora y la jerarquiza (Chen & Guestrin, 2016); (MacQueen, 1967).

7. Conclusiones generales

El modelo propuesto supera ampliamente a las líneas base triviales, por lo que el proyecto sí demuestra valor predictivo más allá de una referencia simple.

La reevaluación oficial muestra que Random Forest logra el mayor F1-macro de prueba, pero también exhibe la señal más fuerte de sobreajuste. En consecuencia, no es la alternativa más sólida para despliegue sin controles adicionales.

La Regresión Logística Multinomial se comporta como un benchmark especialmente valioso porque combina F1 competitivo con excelente generalización. Su inclusión es importante para demostrar que la complejidad de un modelo avanzado debe estar realmente justificada.

XGBoost no lideró por F1 puntual en esta corrida, pero mantiene AUC multiclase competitivo, menor sobreajuste que Random Forest y mayor coherencia con una arquitectura híbrida de cobranzas. Por ello, sigue siendo la opción metodológicamente más defendible como componente supervisado final.

La auditoría de fairness sobre XGBoost identifica diferencias prácticas en intensidad de gestión y presencia de garantía. No constituyen una prueba automática de discriminación, pero sí justifican monitoreo de cohortes y revisión de variables proxy.

El sistema es viable para priorización de cobranzas siempre que se acompañe de tuning adicional, control de generalización, supervisión humana en casos sensibles y documentación explícita de límites de uso.

8. Recomendaciones

En el plano técnico, se recomienda profundizar el tuning de XGBoost con validación externa por factura y early stopping, revisar variables redundantes y consolidar un esquema de calibración de probabilidades antes del despliegue. En el plano metodológico, conviene repetir la auditoría de fairness en cada actualización del modelo y documentar la versión del dataset, el split utilizado y los grupos auditados.

En el plano ético y operativo, la priorización no debería ejecutarse como una decisión totalmente automática cuando confluyan alta incertidumbre, disputa activa o ausencia de garantía. Es preferible que esas condiciones activen revisión humana. Asimismo, las reglas de negocio deben diferenciar entre predicción de riesgo y acción sugerida, de modo que la salida del modelo no se traduzca mecánicamente en una intensificación de cobranza sin contexto.

Finalmente, para fortalecer la madurez del sistema, sería útil realizar una validación temporal más estricta, incorporar monitoreo post-despliegue por cohorte, añadir explicaciones locales para casos de alto impacto y comparar el costo operativo de la solución propia frente a una plataforma administrada bajo escenarios reales de volumen y frecuencia de scoring.

9. Referencias

Barbaglia, L., Manzan, S., & Tosetti, E. (2023). Forecasting Loan Default in Europe with Machine Learning. *Journal of Financial Econometrics, volumen 21, número 2*, 569-596.

Breiman, L. (2001). Random Forests. *Machine Learning, volumen 45, número 1.*, 5-32.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD 2016*, 785–794.

Cox., D. R. (1972). Regression Models and Life-Tables. *Journal of the Royal Statistical Society: Series B (Methodological), volumen 34, número 2.*

Hardt, M., Price, E., & Srebro, N. (2016). Equality of Opportunity in Supervised Learning. *En Advances in Neural Information Processing Systems 29 (NIPS 2016 / NeurIPS 2016).*, 3323-3331.

He, H., & Garcia, E. A. (2009). Learning from Imbalanced Data. *IEEE Transactions on Knowledge and Data Engineering, volumen 21, número 9.*, 1263–1284.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Jonathan, T. (2023). An Introduction to Statistical Learning: with Applications in Python. *Springer Cham, dentro de la serie Springer Texts in Statistics*.

Kaufman, S., Rosset, S., Perlich, C., & Stitelman., O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data (TKDD), volumen 6, número 4, publicado por ACM.*

Lessmann, S., Baesens, B., Seow, H.-V., & Thomas., L. C. (2015). Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research, volumen 247, número 1*, 124-136.

Liu, W., Fan, H., & Xia, M. (2021). Multi-grained and multi-layered gradient boosting decision tree for credit scoring. *Applied Intelligence.*, 5325–5341.

MacQueen, J. B. (1967). Some Methods for Classification and Analysis of Multivariate Observations. *En Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, Volume 1*, 281–297.

Suresh, H., & Guttag, J. V. (2021). A Framework for Understanding Sources of Harm throughout the Machine Learning Life Cycle. *The 1st ACM Conference on Equity and Access in Algorithms,.*